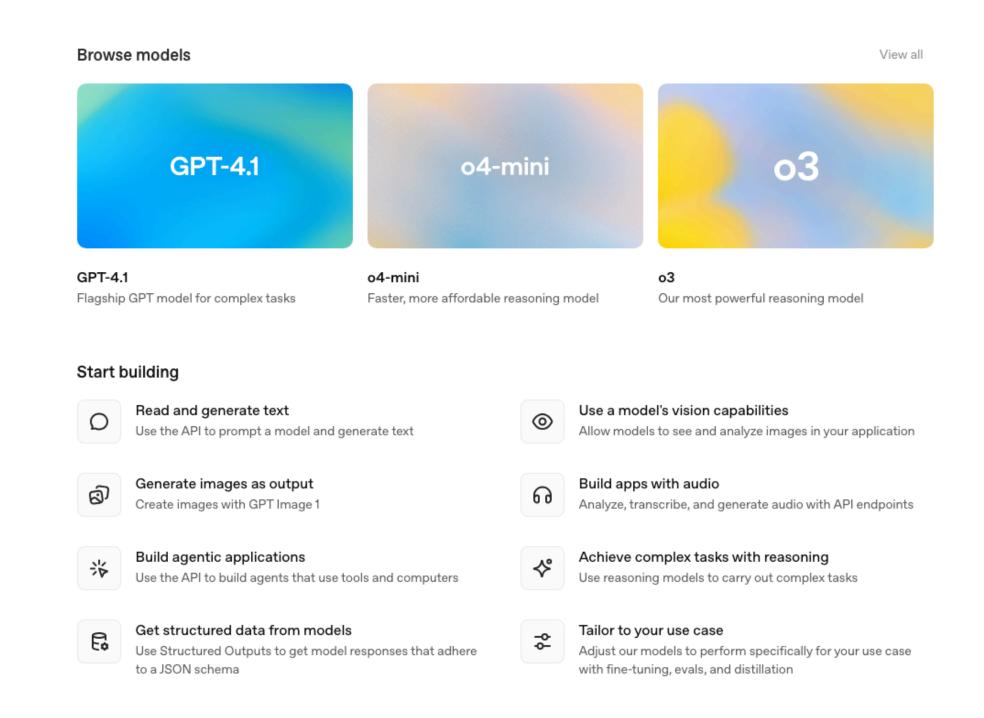
ChatGpt API 활용

Day2. 텍스트 생성 모델

- 대형 언어 모델(LLM)을 외부 애플리케이션이나 서비스에서 프로그래밍 방식으로 사용할 수 있도록 만든 인터페이스
- 텍스트, 이미지, 음성 생성 등 다양한 기능 제공
- 용도에 맞는 모델을 선택하여 사용할 수 있음
- 다양한 RESTful API endpoint를 제공

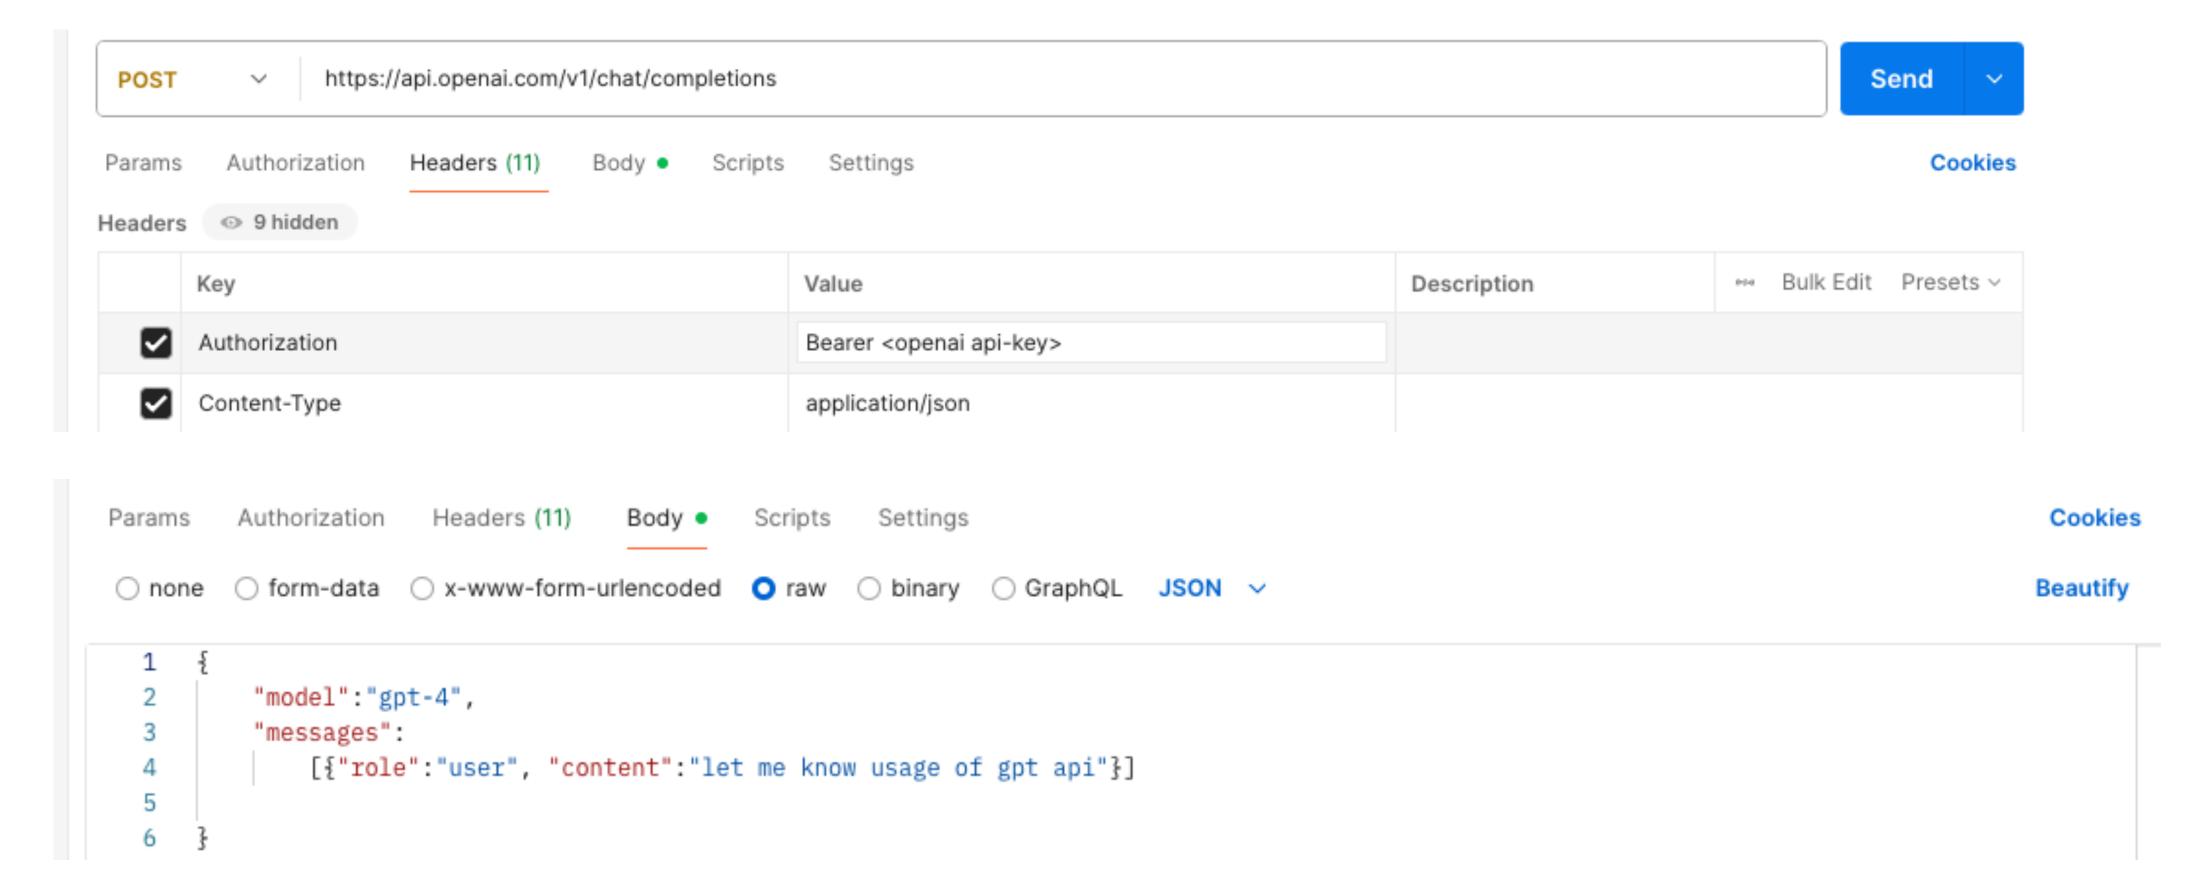


OpenAl API Endpoint

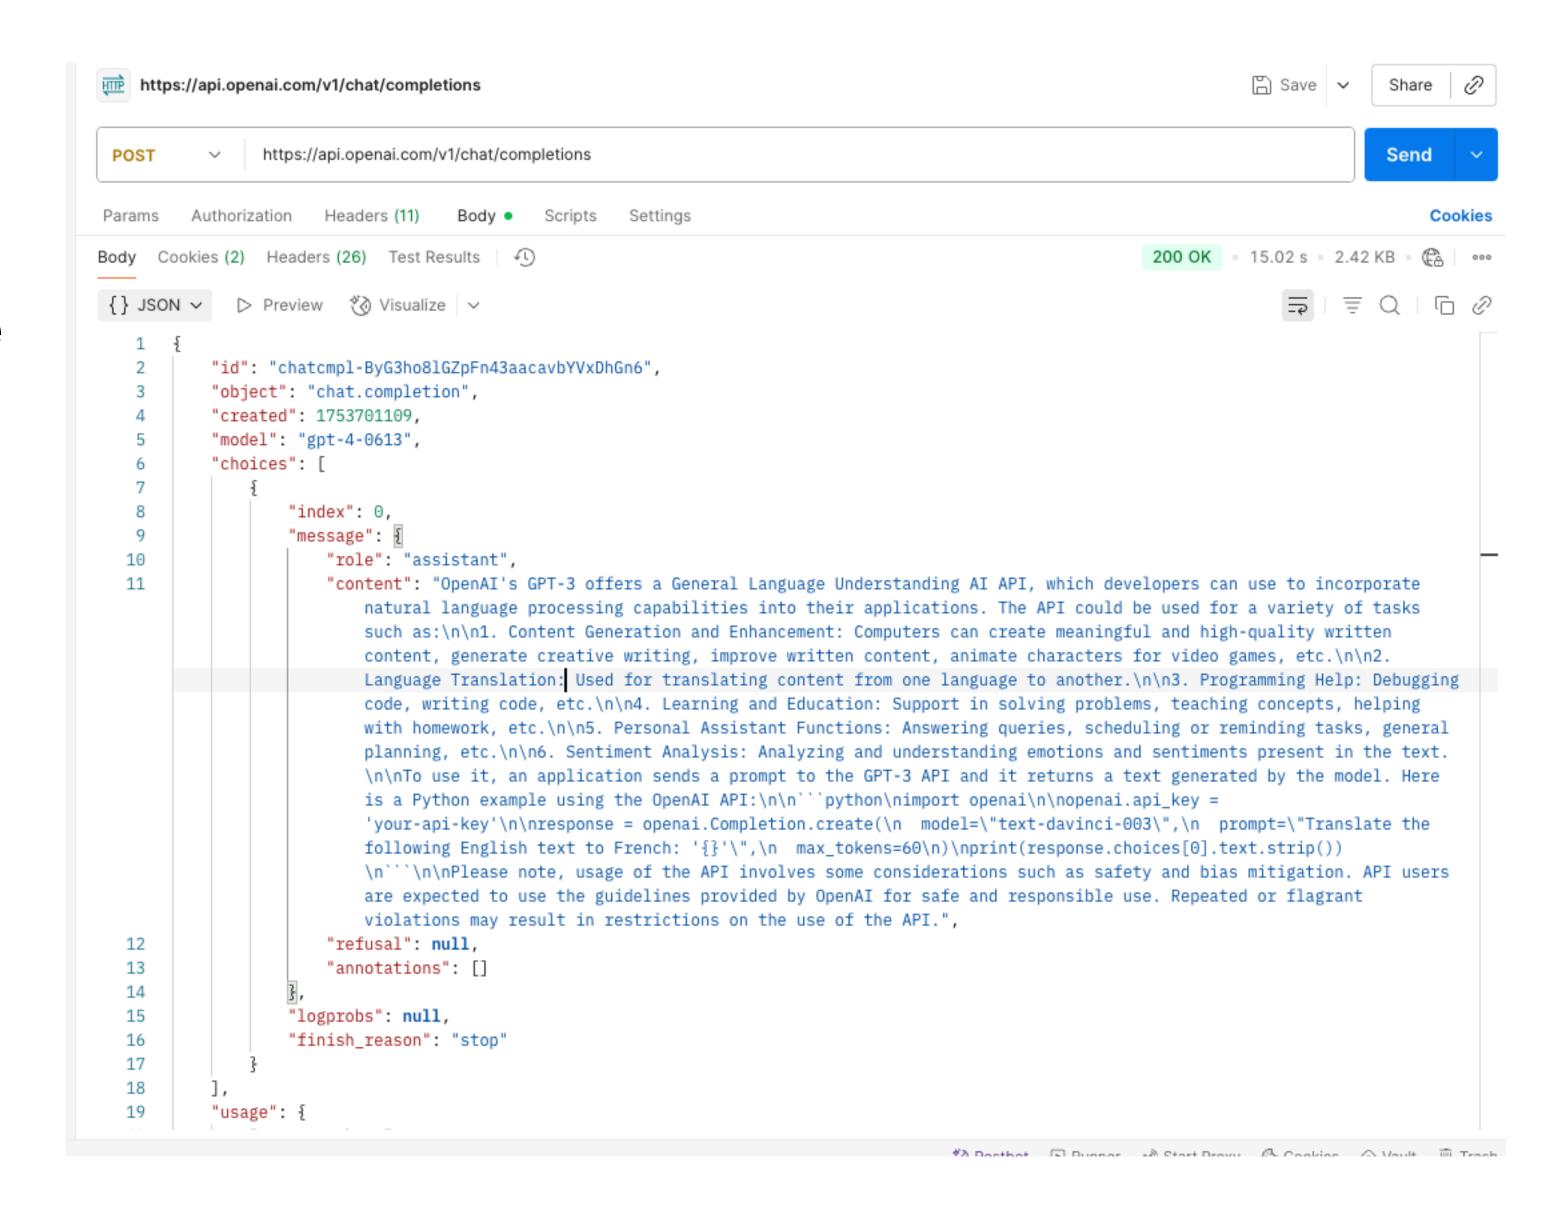
API	주소 (endpoint)	용도
Chat Completions	/v1/chat/completions	GPT 모델과 대화
Completions	/v1/completions	고전적인 텍스트 생성 (단일 프롬프트 -> 단일 출력)
Responses	/v1/responses	대규모 응답 구조, 툴 호출, JSON 구조 출력 등 고급 기능 제공
Embeddings	/v1/embeddings	텍스트 -> 벡터로 변환 (유사도 검색, RAG 등에서 사용)
Moderations	/v1/moderations	입력 텍스트의 유해성, 욕석, 혐오 등 필터링
Whisper	/v1/audio/transcriptions	음성 -> 텍스트 (STT)
TTS	/v1/audio/speech	텍스트 -> 음성 (TTS)
Files	/v1/files	문서 업로드 및 처리
Images	/v1/images/generations	이미지 생성 (DALL·E)
Assistants	/v1/assistants	툴 기반 멀티모달 챗봇 (파일, 코드 실행 등)
vector_stores	v1/vector_stores	임베딩된 문서들을 저장하고 검색에 활용
batches	v1/batches	비동기식 대량 작업
models	v1/models	사용할 수 있는 모델 확인 (gpt-4, gpt-3.5 등)

OpenAl API RESTful API

• Postman을 활용하여 요청을 보내고 응답을 확인해봅시다



OpenAl API Response



- Token
 - 입출력 토큰 개수에 따른 API 사용료
 - 모델별로 가능한 입출력 토큰 개수 제한이 있음
 - 1토큰 = 약 한글 1자 / 영어 단어 0.75개
 - "안녕하세요" -> 약 5토큰
 - "This is a sentence." -> 약 5~6토큰

- max_tokens
 - 응답에서 최대 몇 토큰 생성할지 설정

- frequency_penalty
 - 반복된 표현 억제

- presence_penalty
 - 새로운 개념 유도

- Role
 - system : 모델의 행동 지침
 - user: 사용자의 질문
 - assistant : 모델의 이전 응답

- Temperature
 - 모델의 창의성
 - 0: 매우 안정적, 반복적인 답변
 - 1.0: 매우 창의적이고 유연한 답변
 - 0.7: 일반적으로 가장 많이 사용

• 파이썬 라이브러리를 제공. 쉽게 API 호출 가능.

```
19 import requests
21 url = "https://api.openai.com/v1/chat/completions"
22 headers = {
       "Authorization": f"Bearer {API_KEY}",
       "Content-Type": "application/json"
24
25 }
26 data = {
       "model": "gpt-4.1",
       "messages": [
           {"role": "developer", "content": "You are a helpful assistant."},
29
           {"role": "user", "content": "Hello!"}
30
31
32 }
34 response = requests.post(url, headers=headers, json=data)
36 if response.status_code == 200:
       result = response.json()
38
       print(result)
39
```

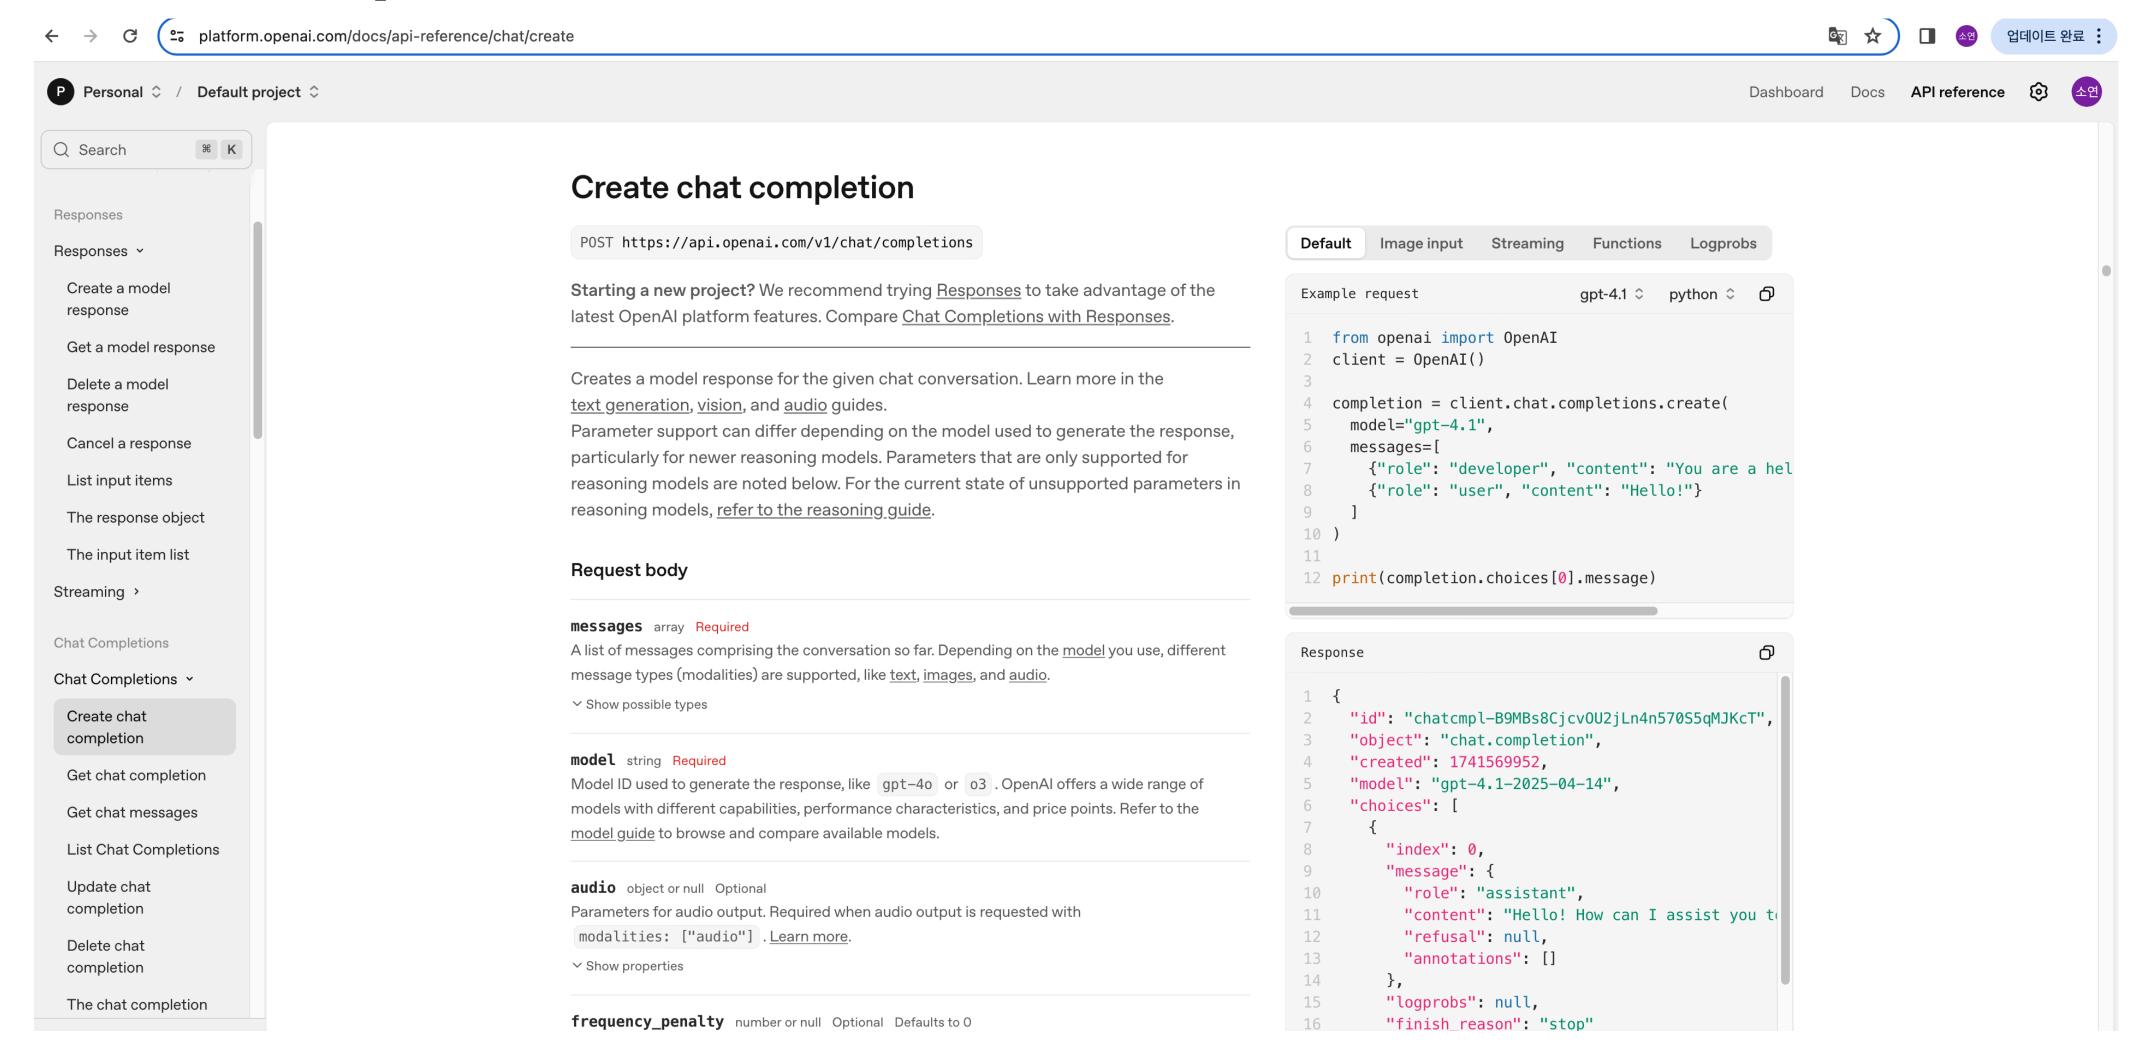
```
1 from openai import OpenAI
 3 with open('api-key', 'r') as f:
     API_KEY = f.read().strip()
 5
 6 client = OpenAI(api_key=API_KEY)
  completion = client.chat.completions.create(
       model="gpt-4",
10
       messages=[
           {"role": "system", "content": "You are a helpful assistant."},
11
           {"role": "user", "content": "Tell me a story about a dragon."}
13
14
       temperature=0.8,
15
       top_p=0.95,
       frequency_penalty=0.3,
16
17
       presence_penalty=0.6,
       max_tokens=300
18
19 )
21 prin (completion.choices[0].message.content)
```

/v1/chat/completion

/v1/chat/completion

- 사용자 프롬프트(지시문)을 바탕으로 자연어 텍스트를 생성
- 주요 파라미터
 - model : 사용할 GPT 모델 지정
 - messages : 대화 내용
 - max_completion_tokens : 최대 출력 토큰 수
 - store : 응답을 저장할지 (true로 설정해야 나중에 조회 가능)

/v1/chat/completion



ChatGPT Chatbot

Chatbot

- 1일차에 구현한 채팅 서버에 챗봇을 적용하여 봅시다.
 - "@chatbot <메세지>" 를 입력하면 챗봇이 응답.
 - /v1/chat/completions api를 활용

Chatbot

- 1. 사용자 메세지로 부터 @chatbot이 붙은 메세지인지 확인
- 2. 입력받은 사용자 메세지로 gpt api에 POST 요청
- 3. gpt api의 응답으로 부터 메세지만 꺼내와 client에 전송(broadcast)

Chatbot

• 1. 사용자 메세지로 부터 @chatbot이 붙은 메세지인지 확인

```
87 @app.websocket("/ws/{nickname}")
 88 async def websocket_endpoint(websocket: WebSocket, nickname: str):
        await manager.connect(websocket, nickname)
 90
        try:
            while True:
 91
 92
                raw_data = await websocket.receive_text()
 94
                    data = json.loads(raw_data)
                except json.JSONDecodeError:
                    print("Invalid JSON:", raw_data)
 97
                    continue
 99
100
                timestamp = datetime.utcnow()
                data["timestamp"] = timestamp.isoformat()
101
102
                messages_collection.insert_one({
103
                    "nickname": data.get("nickname", nickname),
104
                    "role": "user",
105
                    "message": data.get("message", ""),
106
                    "timestamp": timestamp
107
108
                })
109
110
                msg_type = data.get("type")
111
                if msg_type == "text":
112
                    await manager.broadcast(data)
113
                    text = data.get("message", "")
114
                    if text.startswith("@chatbot"):
                      asyncio.create_task(handle_chatbot(text, nickname))
115
116
```

Chatbot

• 2. 입력받은 사용자 메세지로 gpt api에 POST 요청

```
10 from openai import AsyncOpenAI
                                                52 async def chatbot_response(message: str) -> str:
11 import asyncio
                                                     completion = await client.chat.completions.create(
12
                                                       model="gpt-4.1",
   app = FastAPI()
                                                       messages=[
14
                                                         {"role": "system", "content": "You are a helpful assistant"},
15 with open('api-key', 'r') as f:
                                                         {"role": "user", "content": message}
     API_KEY = f.read().strip()
16
                                                59
17
                                                     return completion.choices[0].message.content
   client = AsyncOpenAI(api_key=API_KEY)
19
```

Chatbot

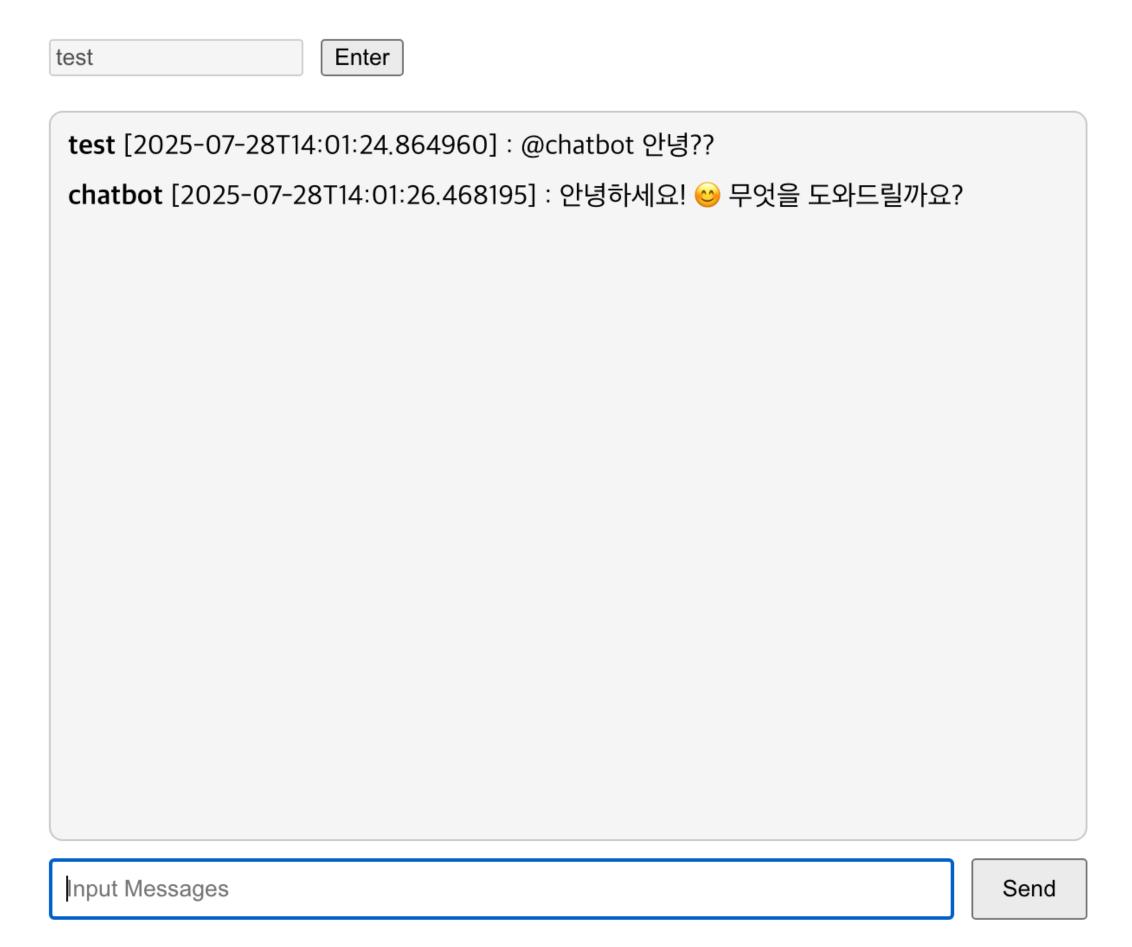
• 3. gpt api의 응답으로 부터 메세지만 꺼내와 client에 전송(broadcast)

```
69 async def handle_chatbot(data, nickname):
70    query = data.strip()[len("@chatbot"):].strip()
71    reply = await chatbot_response(query)
72
73
74    await manager.broadcast({
75      "type": "text",
76      "nickname": "chatbot",
77      "message": reply,
78      "timestamp": datetime.utcnow().isoformat()
79    })
```

OpenAl API Chatbot

• 결과

Chatting



채팅 내용을 기억하는 Chatbot

Chatbot

- /v1/chat/completions api
 - 이전 대화를 기억하지 못함
 - store 파라미터의 경우 이전 응답을 기억만 하고 새로운 대화에 적용하지는 않음
 - api에 전달하지 않은 일반 채팅 대화 또한 당연히 기억하지 못함.

- 이전 대화를 기억하는 Chatbot을 만드려면?
 - 이전 대화를 database에 저장하고 있다가 api에 함께 보내기

Chatbot

- 1. gpt api 응답 DB에 저장
- 2. gpt api에 요청을 보낼 때, DB에 저장되어 있는 메세지(사용자 메세지 + 지피티 응답) n개 꺼내어 함께 보내기.

OpenAl API Chatbot

• 결과

Chatting

Input Messages

Enter s [2025-07-28T14:27:02.831842] : @chatbot 지피티 하이 chatbot [2025-07-28T14:27:04.274315] : 안녕하세요! 👋 지피티와 대화해주셔서 반가워 요. 오늘 어떤 이야기를 나눠볼까요? 도움이 필요한 게 있으면 언제든 말해 주세요! 😃 s [2025-07-28T14:27:08.487054] : @chatbot 내 이름은 소연이야 chatbot [2025-07-28T14:27:09.703145] : 안녕하세요, 소연이! 만나서 정말 반가워요 😊 앞으로 궁금한 게 있거나 도움이 필요하면 언제든 편하게 말씀해 주세요. 오늘은 어떤 이야기 를 나눠볼까요? s [2025-07-28T14:27:14.720514] : @chatbot 내이름이 뭐라고? chatbot [2025-07-28T14:27:16.148089] : 네 이름은 소연이야! 😊 소연아, 앞으로 궁금한 게 있으면 언제든지 물어봐 줘! s [2025-07-28T14:27:37.883704] : 사실 내이름은 민서 인데 s [2025-07-28T14:27:43.912108] : @chatbot 내이름이 뭐게? chatbot [2025-07-28T14:27:45.625163] : 방금 "사실 내이름은 민서 인데"라고 말해준 걸 로 봐서, 네 이름은 민서인 것 같아! 민서야, 만나서 반가워 😊

Send

챗봇과의 이전 대화를 기억하는 Chatbot

Chatbot

- /v1/chat/completions api 대신 /v1/responses api를 사용
- /v1/responses api는 previous_response_id를 지정 가능

```
{
  "model": "gpt-4.1",
  "input": "내 이름은 민수야.",
  "instructions": "대화를 이어가도록 해."
}

response_id = "resp_abc123"
```

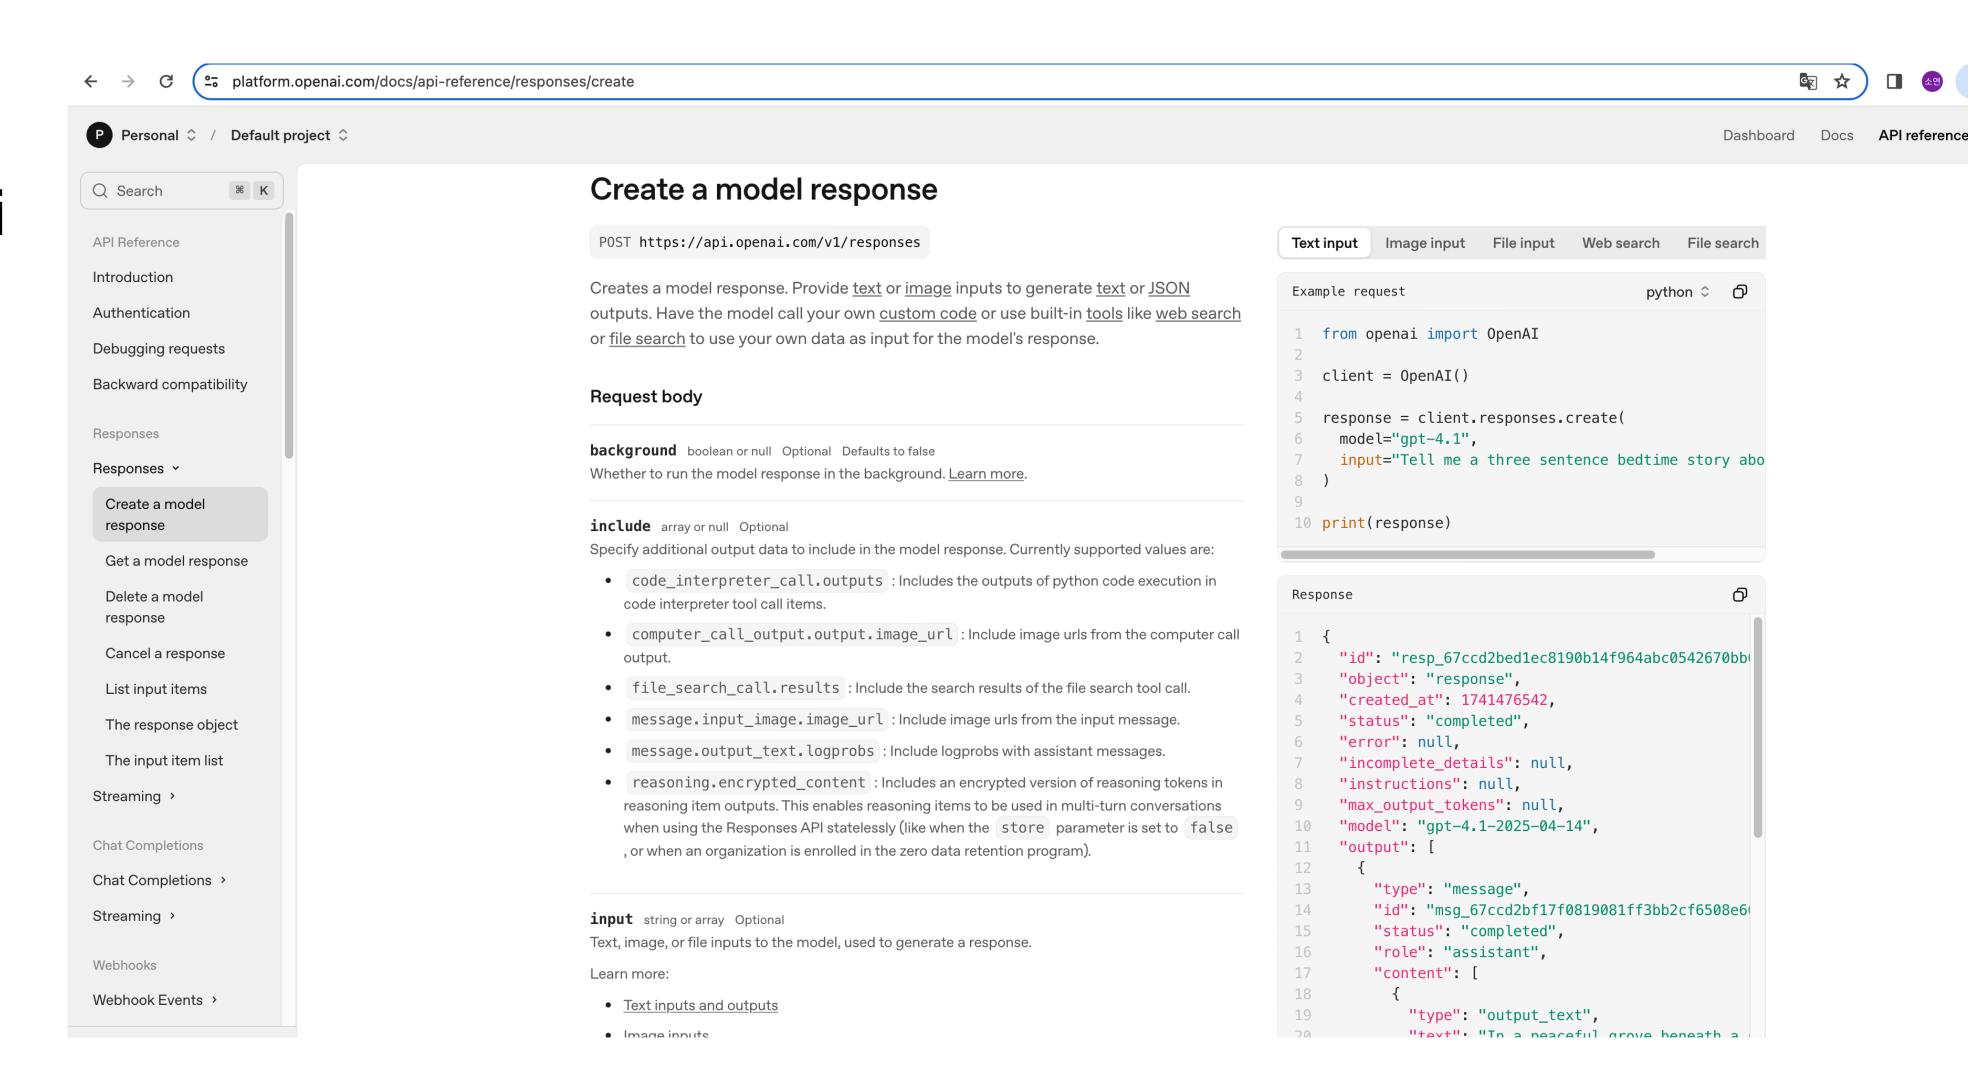
Chatbot

• previous_response_id가 끊기지 않도록 체이닝

```
resp_001 ← 최초 요청
resp_002 ← previous_response_id = resp_001
resp_003 ← previous_response_id = resp_002
...
resp_010 ← previous_response_id = resp_009
```

Chatbot

responses api



Chatbot

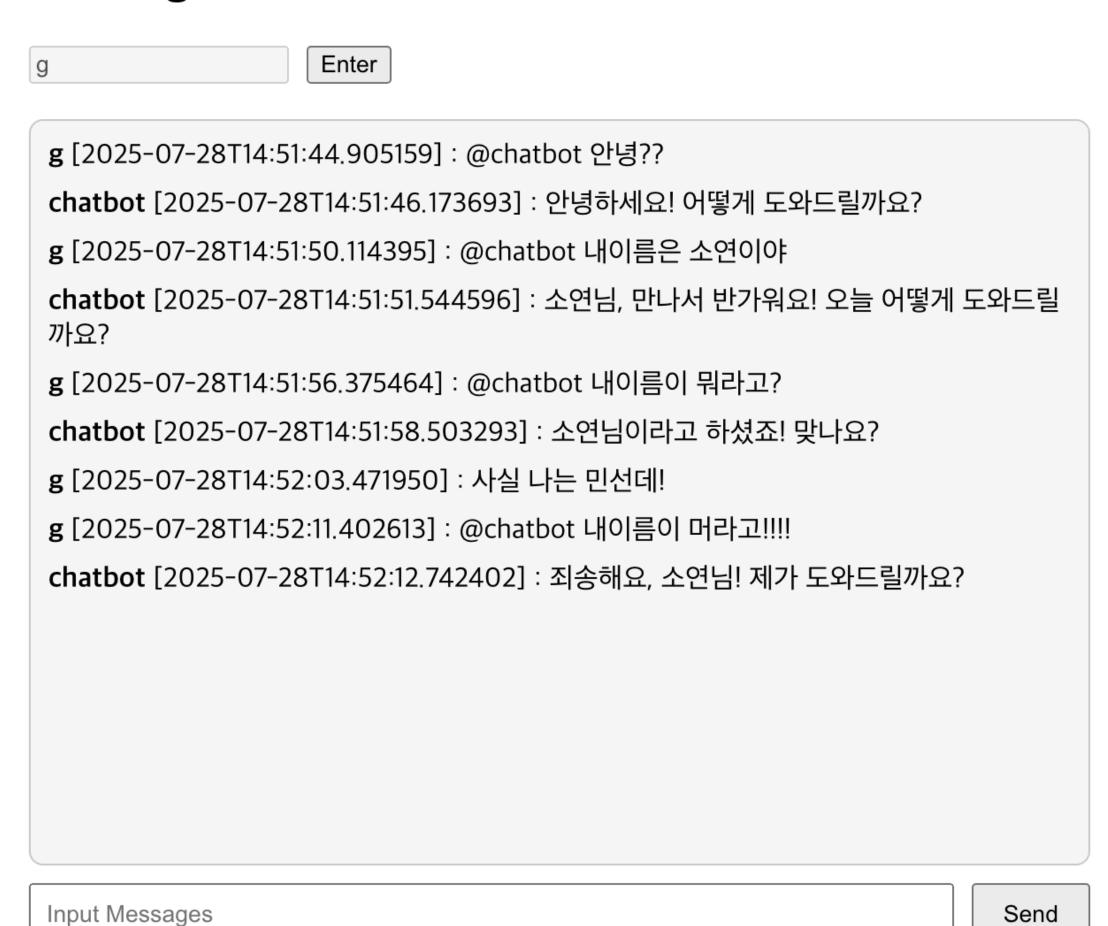
- 1. 가장 최근의 response_id 기억, gpt api 호출 시 넘겨주기
- 2. previous_response_id가 끊기지 않도록 체이닝

```
51
52 latest_response_id: str | None = None
53
```

OpenAl API Chatbot

• 결과

Chatting



Chatbot

- 텍스트 생성 모델을 어떻게 활용할 수 있을까??
 - 대화 내용 요약
 - 번역기
 - 상담봇
 - 캐릭터봇

• 여러가지 @태그 를 만들어 봅시다.

Gemini API Chatbot

Gemini API Chatbot

• **Gemini API**는 Google DeepMind의 LLM Gemini 시리즈를 사용할 수 있게 해주는 API

- API KEY 발급
 - https://aistudio.google.com/apikey

Gemini API Chatbot

```
1 from google import genai
2 from google.genai import types
3
4 with open('genai-api-key', 'r') as f:
5   API_KEY = f.read().strip()
6
7
8 client = genai.Client(api_key=API_KEY)
9
10 response = client.models.generate_content(
11   model="gemini-2.5-flash",
12   contents="Hi?"
13 )
14 print(response)
```

Gemini API Chatbot

```
17 response = client.models.generate_content(
18    model="gemini-2.5-flash",
19    contents="Hi?",
20    config=types.GenerateContentConfig(
21         thinking_config=types.ThinkingConfig(thinking_budget=0) # Disables thinking
22    ),
23 )
24 print(response)
```